

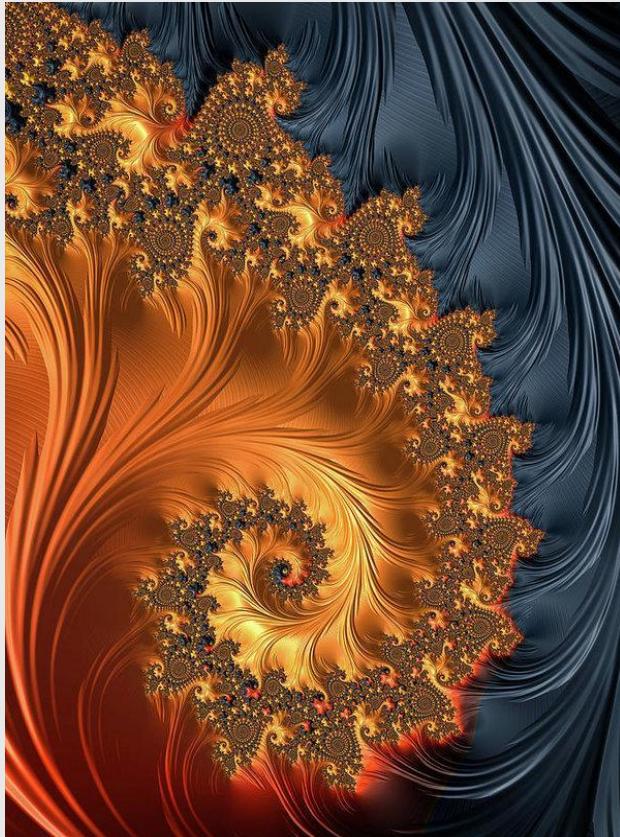


WORKSHOP:

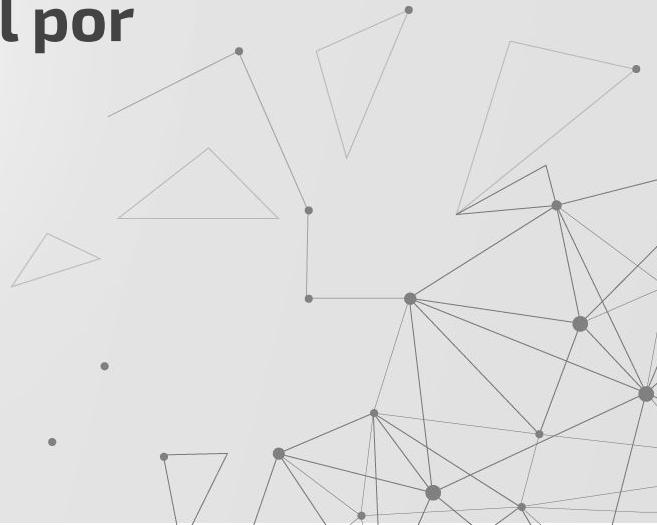
Representation Learning

Building an artificial contextual cortex

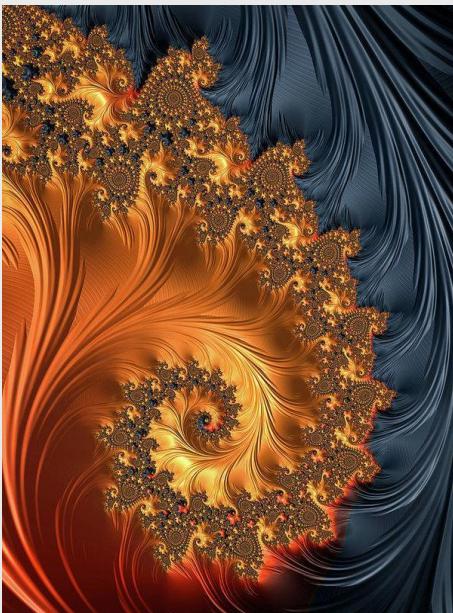
Ricardo Mansilla
LASI, **Co-Founder & CEO**



**¿Qué puede hacer nuestro cerebro
después de ver un fractal por
primera vez?**



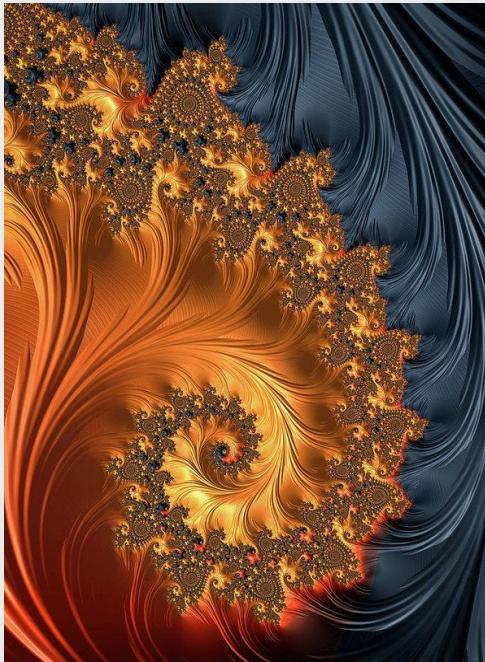
- Diferenciar entre un fractal y un gato



- Diferenciar entre un fractal y un gato
- En un pedazo de papel, pintar “como se ve” un fractal

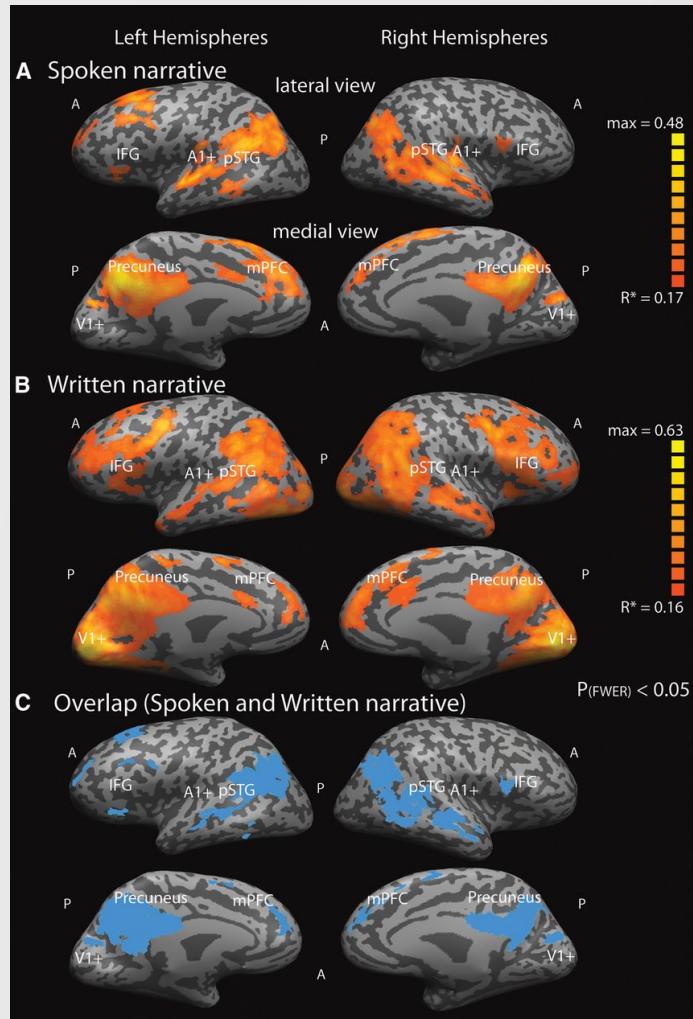


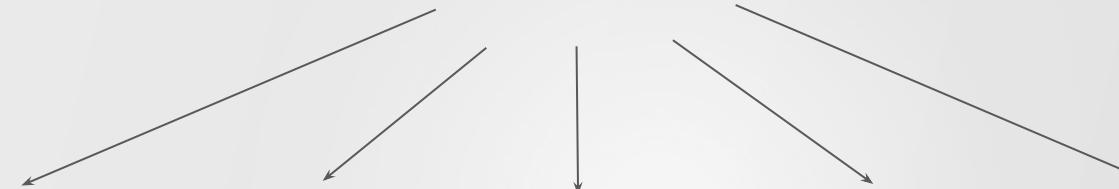
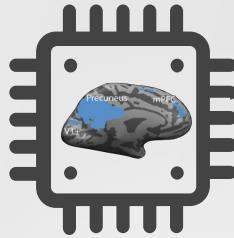
- Diferenciar entre un fractal y un gato
- En un pedazo de papel, pintar “como se ve” un fractal
- Clasificar imágenes de fractales de no-fractales



- Diferenciar entre un fractal y un gato
- En un pedazo de papel, pintar “como se ve” un fractal
- Clasificar imágenes de fractales de no-fractales
- Cerrar los ojos e imaginar cómo se vería una imagen gato-fractal







Escribir



Comunicar



Clasificar

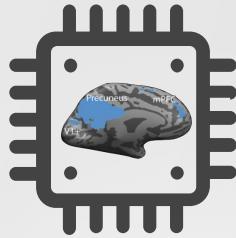


Pintar



Imaginar





Escribir



Comunicar



Clasificar



Pintar



Imaginar

Capacidad de representación

Generalización

Adaptabilidad

Instalación del software



APRENDIZAJE ARTIFICIAL

Machine learning supervisado y no-supervisado

APRENDIZAJE NO SUPERVISADO

Aprendizaje no supervisado de patrones: métodos y comparaciones

REDES NEURONALES

Redes neuronales en una diapositiva

01

02

03

CONTENIDO

04

05

06

REPRESENTATION LEARNING

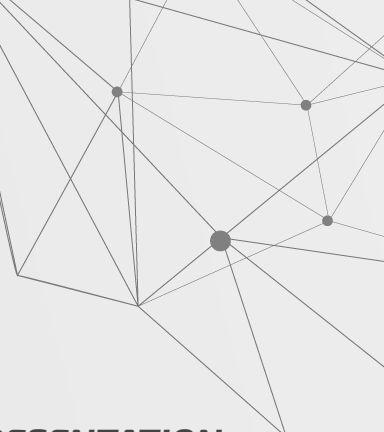
Aprendizaje de patrones no supervisado con **NN**

WORKSHOP

Construyendo un cortex conceptual artificial

OTROS CASOS DE USO

Otros casos de uso y posibles aplicaciones futuras de **RL**



01

Aprendizaje artificial



Nuestra definición de AI

Dartmouth Conference 1965

Resume: "...cualquier aspecto del aprendizaje artificial o cualquier característica de la inteligencia que pueda ser descrita de forma precisa por una computadora"

Definición popular

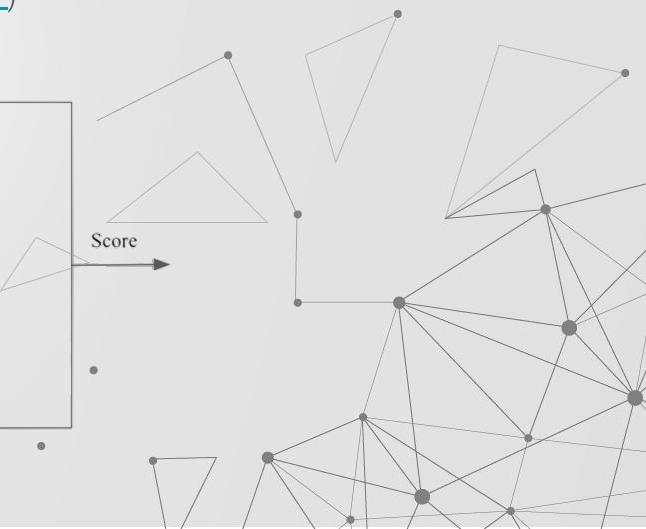
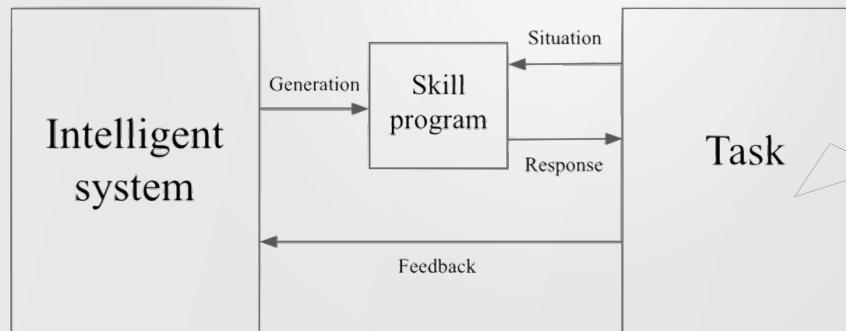
La teoría y desarrollo de sistemas computacionales capaces de llevar a cabo tareas que normalmente requerirían inteligencia humana.



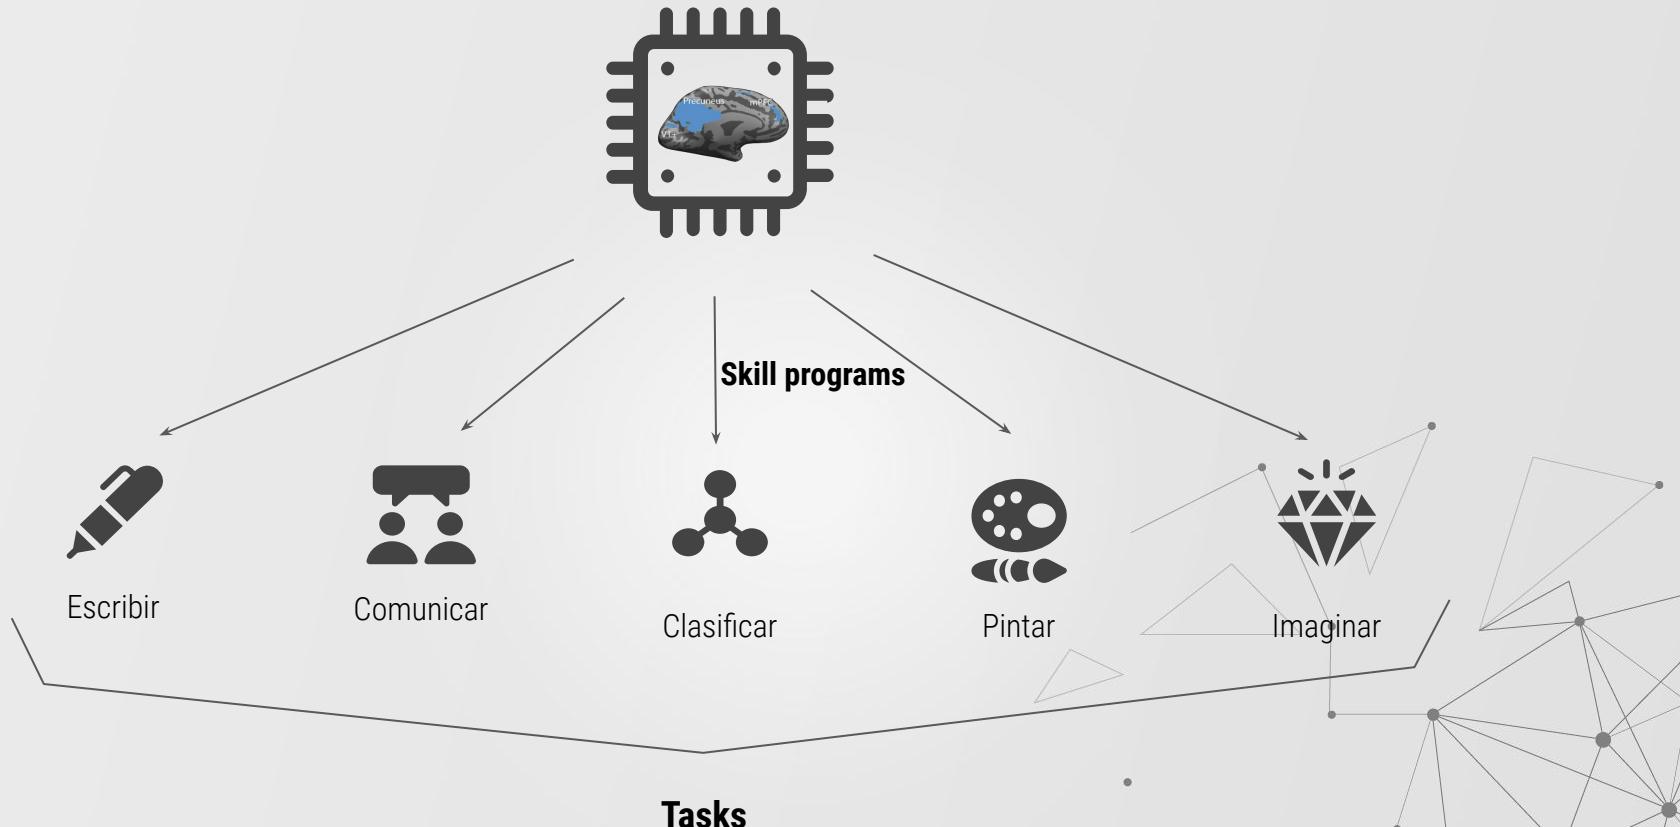
Nuestra definición de AI

La inteligencia de un sistema es una medida de su eficiencia adquiriendo habilidades en un rango de tareas, de acuerdo a determinado conocimiento previo y experiencia adquirida, y de acuerdo a una dificultad de generalización.

- **F. Chollet**, *On the Measure of Intelligence*, 2019 (<https://arxiv.org/abs/1911.01547>)



Intelligent System



Supervisado

Se requiere tener una base de conocimiento previa

La computadora necesita que "actualicen" su conocimiento

Necesita "ayuda" humana para seguir aprendiendo



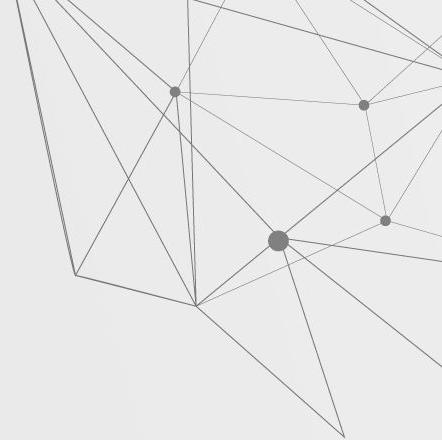
Aprendizaje Supervisado Vs No supervisado

No supervisado

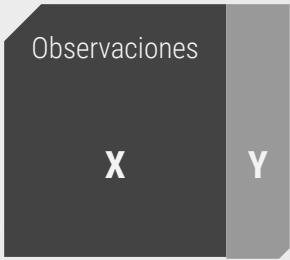
Las máquina infiere patrones por si sola

No requiere base de conocimiento

Es capaz de aprender "constantemente"



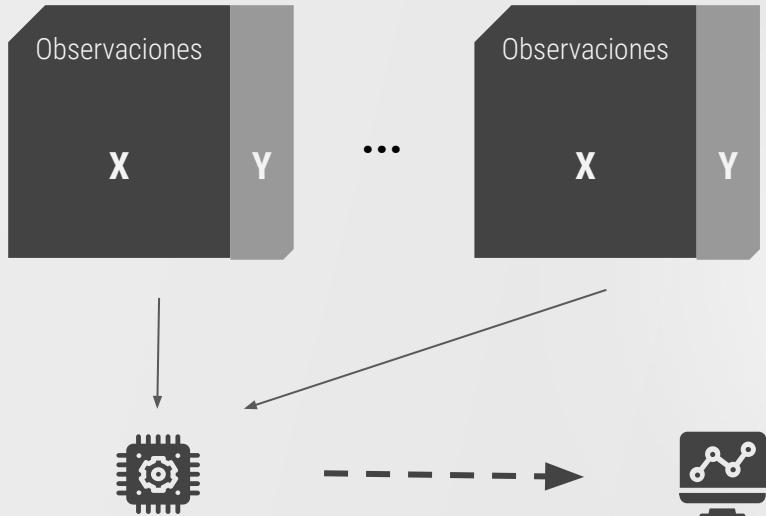
Aprendizaje supervisado



Aprendizaje no supervisado



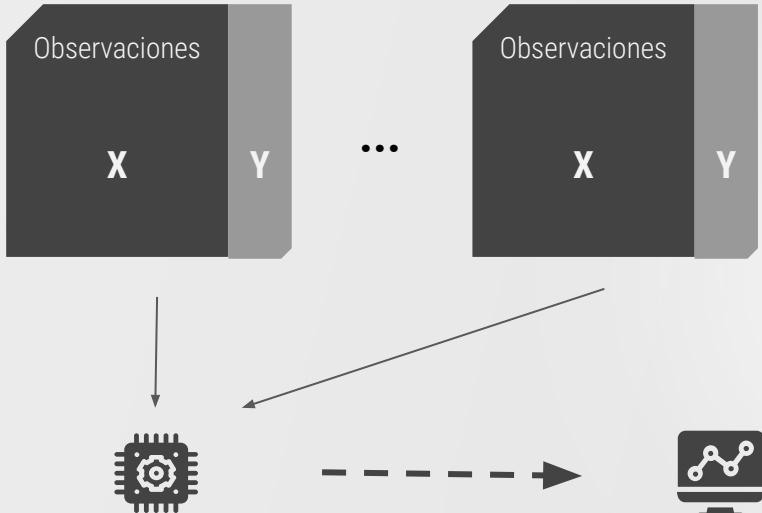
Aprendizaje supervisado



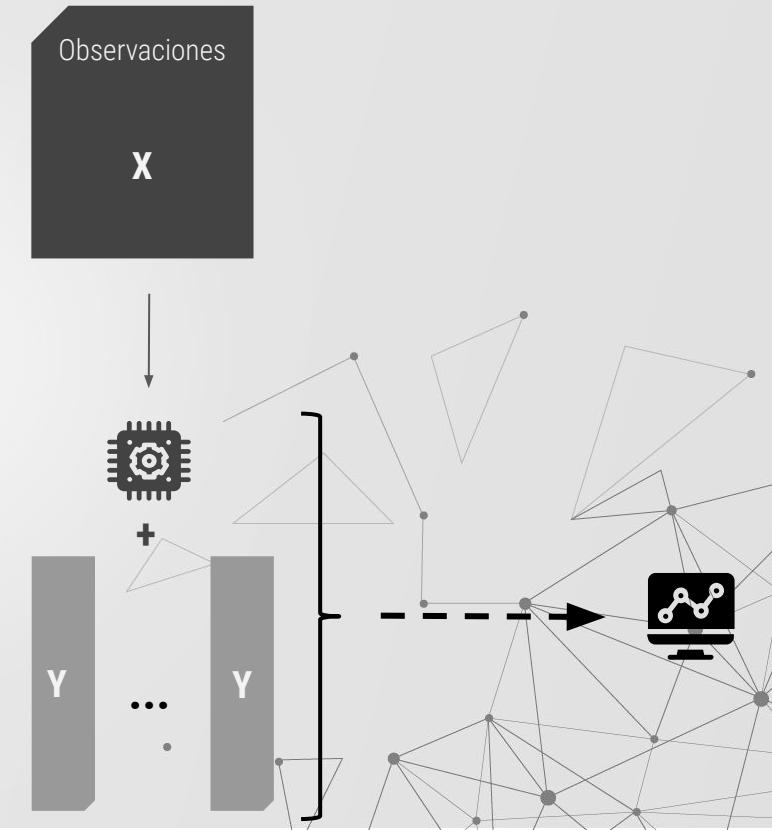
Aprendizaje no supervisado



Aprendizaje supervisado



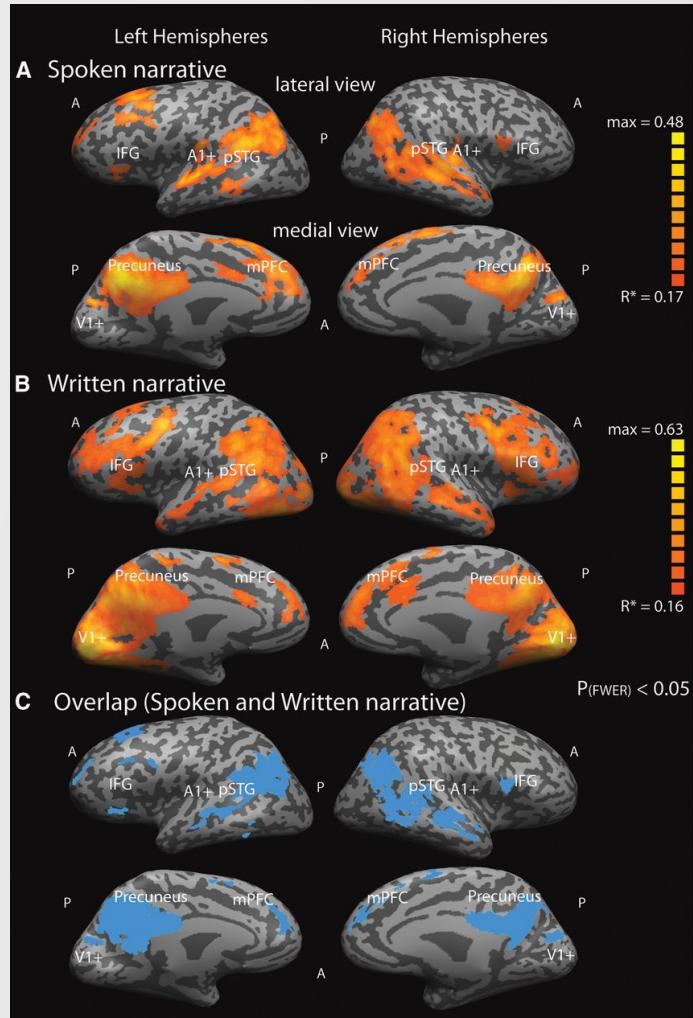
Aprendizaje no supervisado





02

Aprendizaje no supervisado



Aprendizaje no supervisado

- Queremos caracterizar la información sin supervisión humana
- La máquina es capaz de “elegir” qué aprender
- Tratamos de aprender features (patrones) mas “fundamentales” en los datos
- Es posible usar estas representaciones en diversos problemas (*transfer learning*)



Aprendizaje no supervisado

Feature Learning

Aprendizaje de características (features) en los datos de manera no supervisada

Representation Learning

Aprendizaje de representaciones de los datos de manera no supervisada



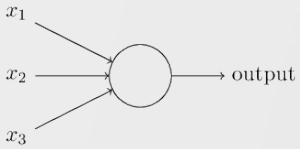
03

REDES NEURONALES



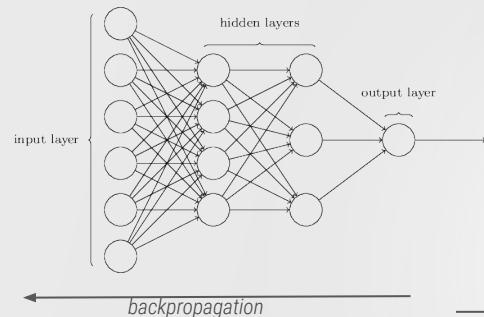
REDES NEURONALES

Perceptrones



- El perceptrón es la unidad mínima de procesamiento de una red neuronal

- *Back propagation* es el mecanismo por el cual se "entrena" la red neuronal

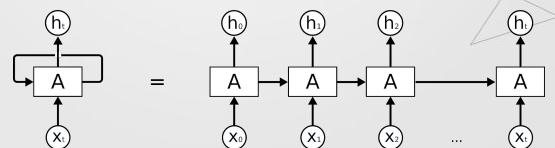


Técnicas de entrenamiento

- Cambiar el costo cuadrático por otros
- Funciones de activación
- Técnicas de regularización
- Inicialización de pesos

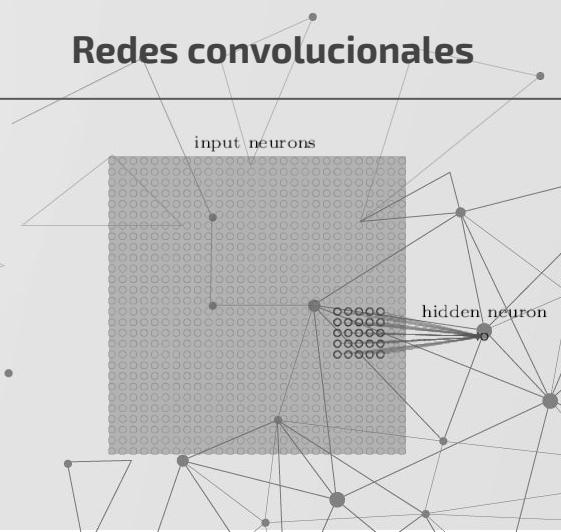
Redes recurrentes

- Las redes con capas conectadas a ellas mismas



Ejemplo: <https://playground.tensorflow.org/>

Redes convolucionales



The background of the slide features a complex, abstract network graph composed of numerous dark grey circular nodes and thin grey lines representing connections. Some nodes are highlighted with larger circles, while others are smaller. In the upper right quadrant, there are several light grey triangular shapes of varying sizes, some pointing towards the center and others pointing away. The overall effect is one of data connectivity and structure.

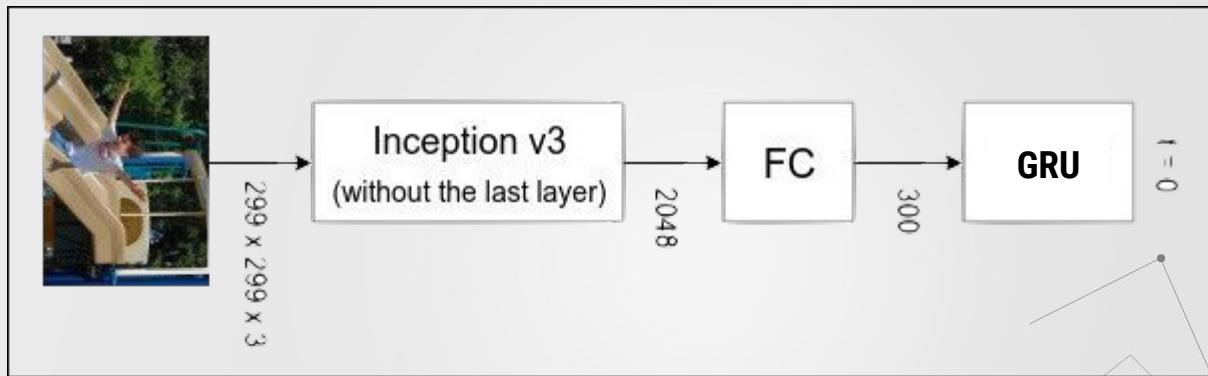
04

Representation Learning

Extracción no supervisada de features para varios casos de uso

Arquitectura: Descripcion de imagenes

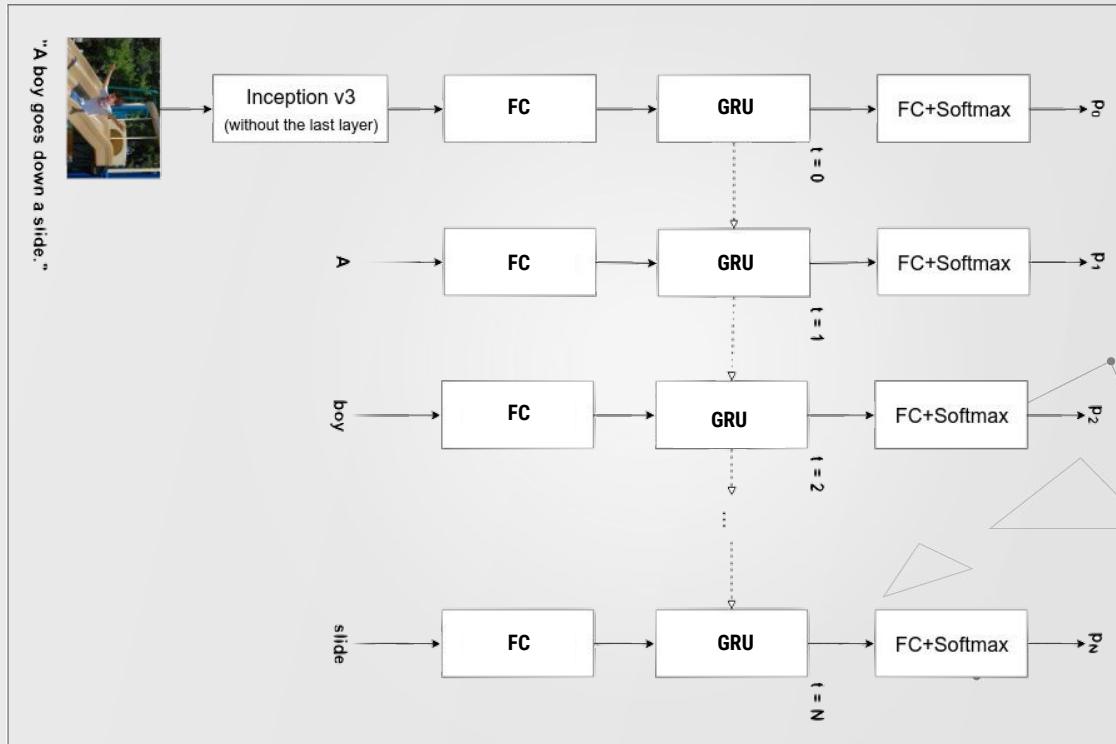
(image captioning)



<https://daniel.lasiman.com/post/image-captioning/>

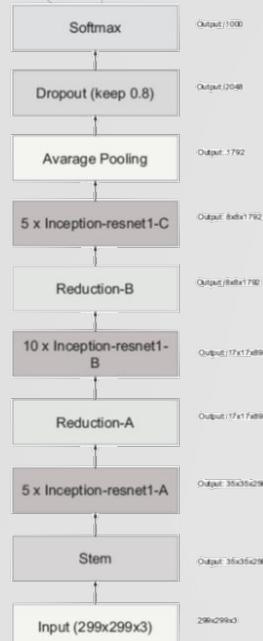
Arquitectura: Descripcion de imágenes

(image captioning)

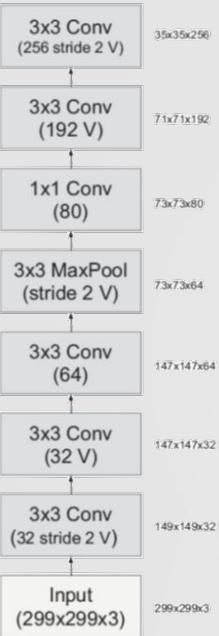


Arquitectura: Inception v4

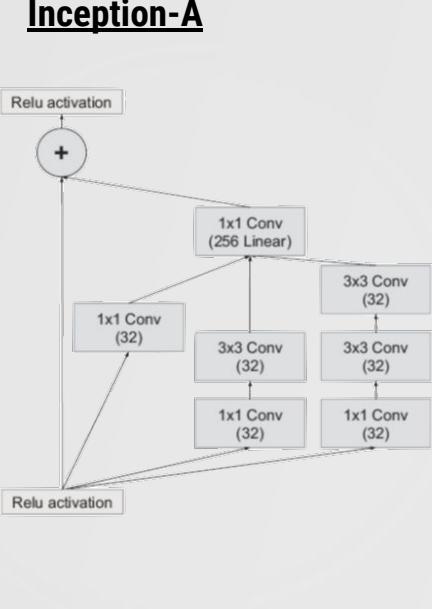
Red Completa



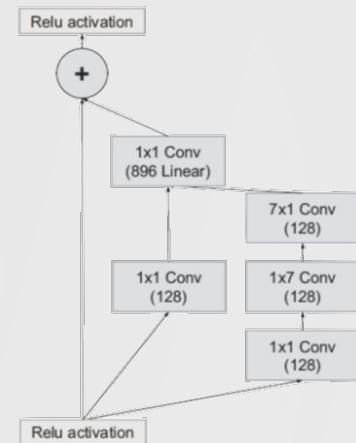
Stem module



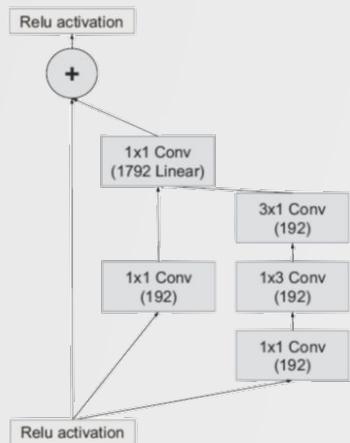
Inception-A



Inception-B

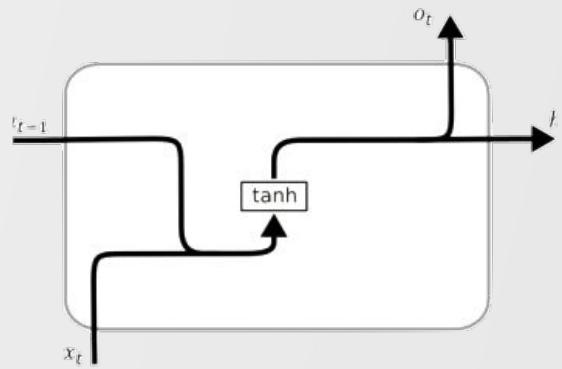


Inception-C

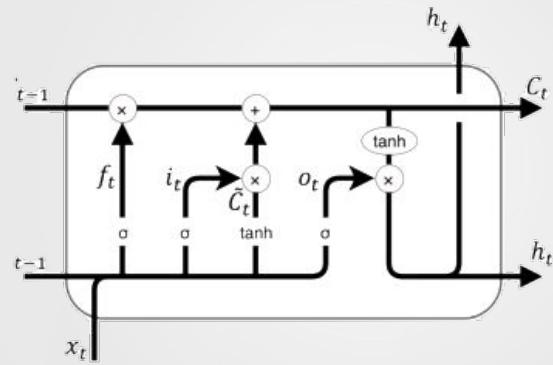


Arquitectura: RNNs

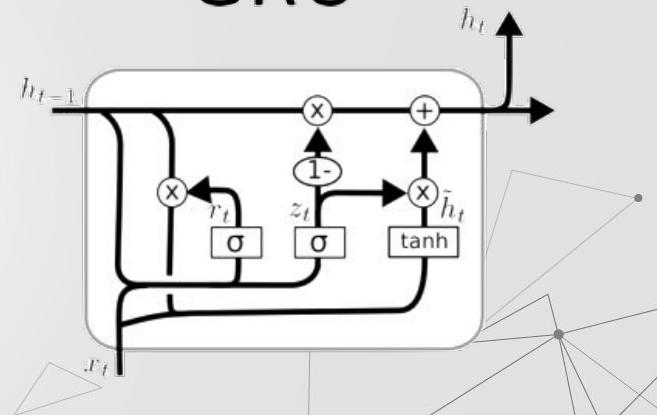
RNN



LSTM



GRU



Arquitecturas: LSTM

Forget gate:

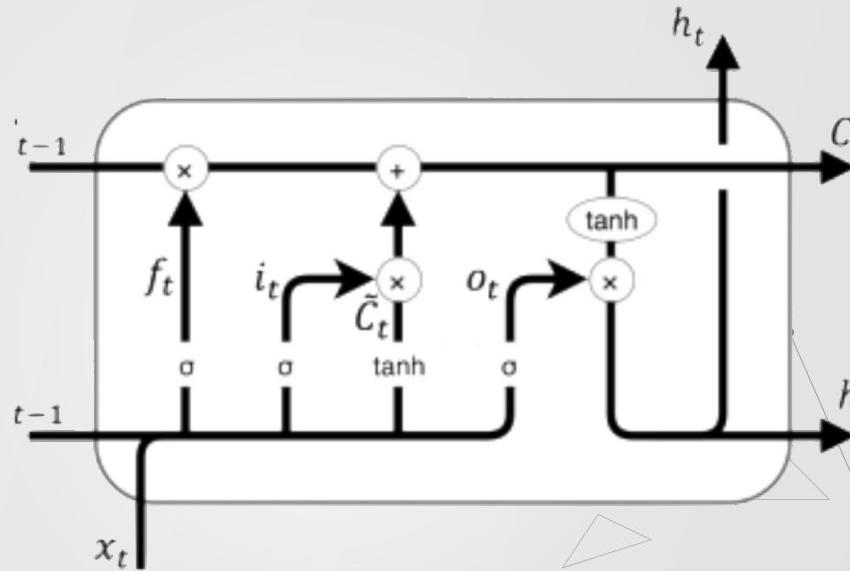
Decide qué información **ignorar** de pasos anteriores.

Input gate:

Qué información es relevante **agregar** en el paso actual.

Output gate:

Decide qué información **regresar** para el próximo paso (nuevo estado).



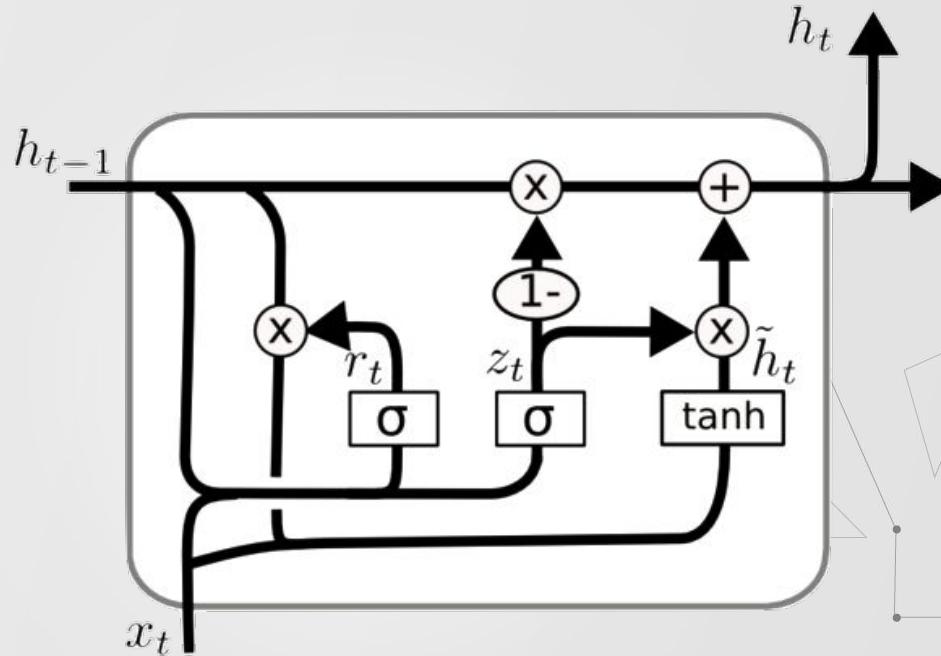
Arquitecturas: GRU

Update gate:

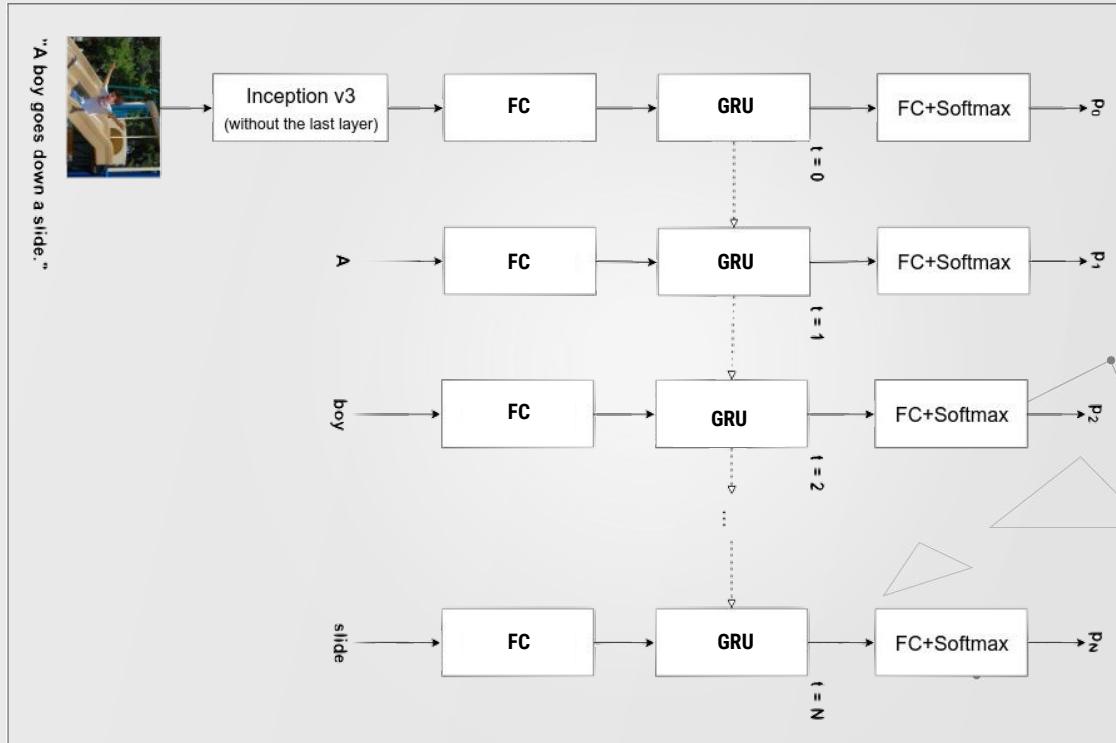
Es una especie de *forget* e *input*, decide que **tirar** y que **agregar** en el paso actual.

Reset gate:

Otra compuerta para **ignorar** información pasada.



Arquitecturas: *Image captioning*



05

WORKSHOP

Construyendo un cortex conceptual artificial

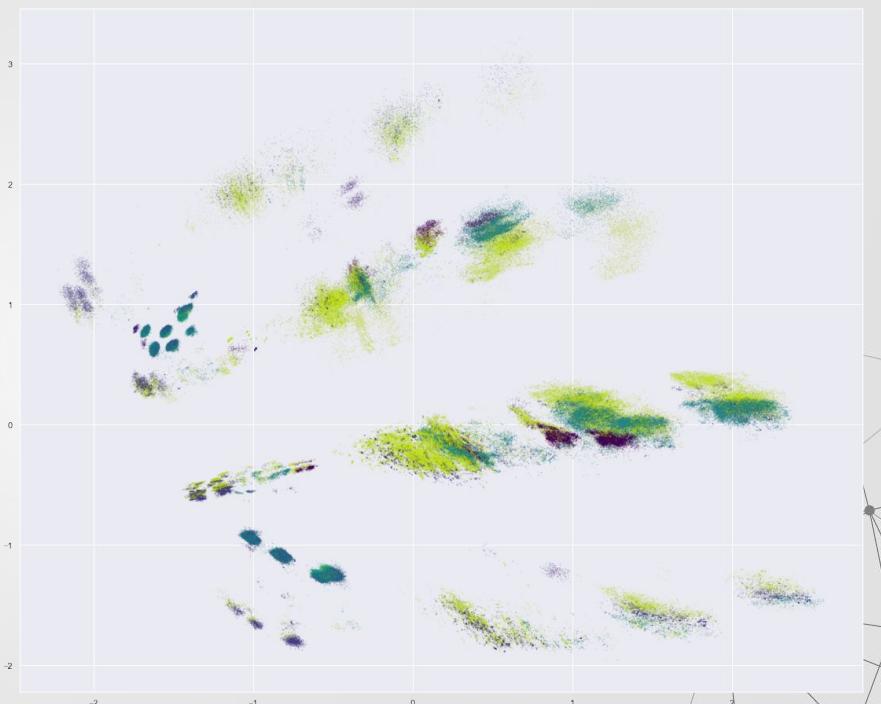


06

OTROS CASOS DE USO

Detección de fraude en sistemas de pagos online

- Entrenamos un **VAE** sobre los datos “limpios” con algunos términos de regularización adicionales.
- El *accuracy* del sistema mejoró 15% sobre el conjunto de entrenamiento (supervisado).
- Features del **VAE** fueron los más significativos.
- Surgió la pregunta: ¿qué más se puede hacer con estas representaciones?



Detección de fraude en sistemas de pagos online



Detección de fraude



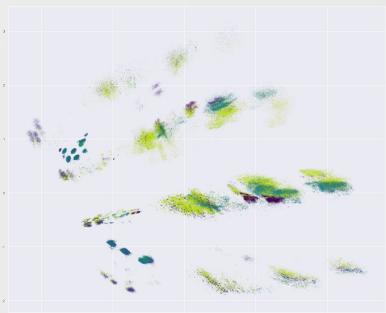
Detección de anomalías



Customer Value Inference



Sistemas de Recomendación

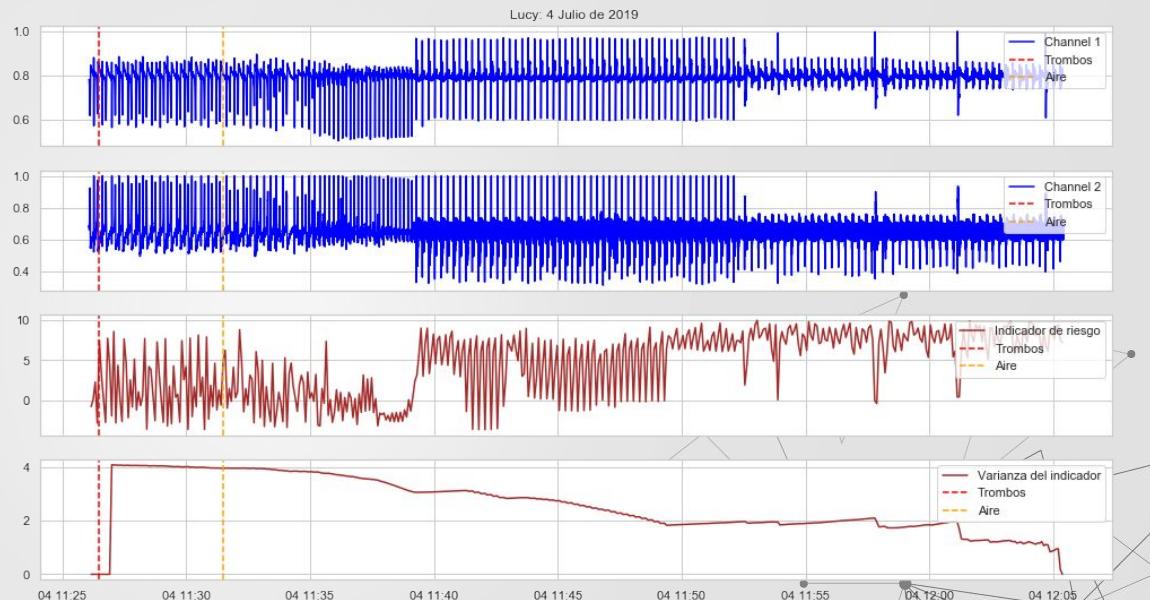


Business Intelligence



Deconstrucción de señales médicas

- LSTM+VAE para generar *embeddings* temporales (ventanas de tiempo).
- La señal de perturbación es bastante significativa **> 3 min** antes del colapso.
- ¿Las dimensiones del *embedding* pueden ser usadas para predecir otro fenómeno?
- ¿Distintos sistemas biológicos se caracterizan en dinámicas distintas?



Deconstrucción de señales médicas



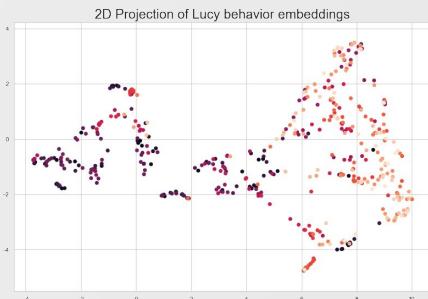
Diagnóstico



Alertas Tempranas



Investigación metodológica



Medical Intelligence



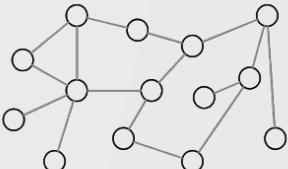
Caso de estudio

Neural structured learning

Neural Structured Learning

(https://www.tensorflow.org/neural_structured_learning)

Training samples with labels

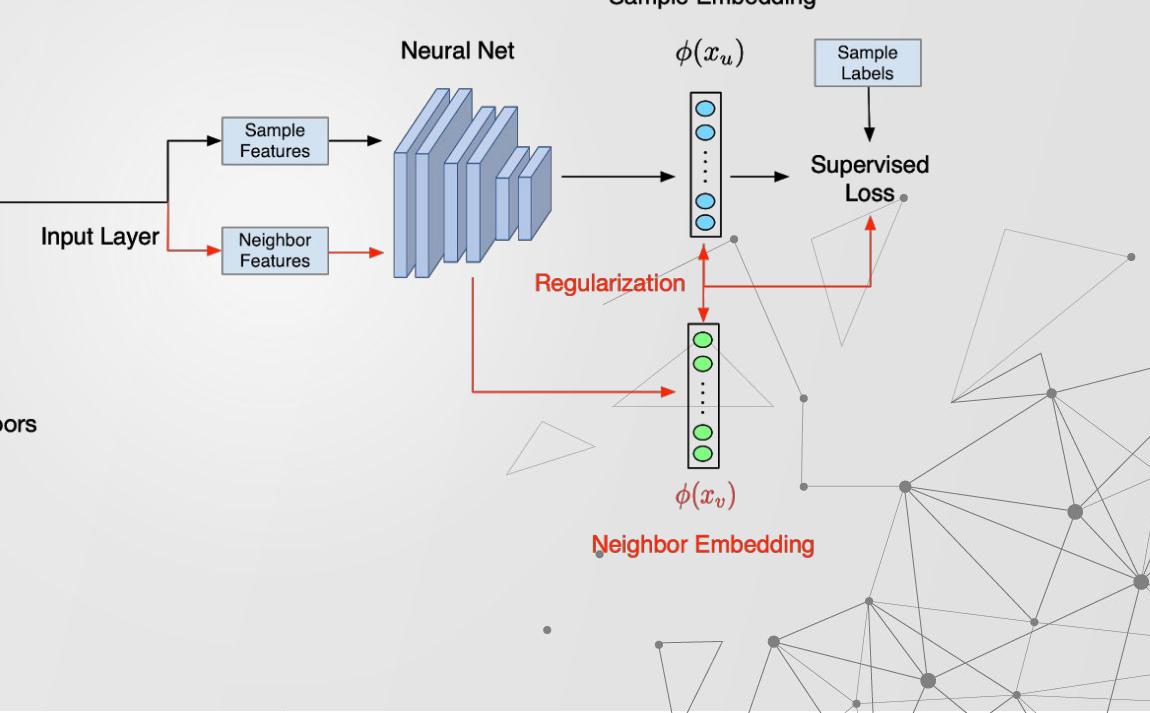


Structured signals (e.g., graphs)

Batch of labeled samples with neighbors

Sample 1
Neighbor 1
...
Neighbor K
⋮
Sample N
Neighbor 1
...
Neighbor K

Input Layer





Ricardo Mansilla, **Co-Founder & CEO**

Gracias